



Dataset para Reconocimiento

Sistema de Control de Acceso para el Campus Universitario

Valadez Carmona Guadalupe Yamileth
Rodríguez Cervantes Kevin Manzur
Viveros Hernández Alejandro

Administración de Proyectos 1



Tlamati Access

14 – mayo – 2026

DV-1.1.0



Control de versiones

Versión	Fecha	Autor	Cambios realizados	Aprobado
DV-1.0.0	2026-05-14	Yamileth	Versión inicial del documento Datasets para Reconocimiento	Manzur
DV-1.1.0	2026-05-14	Manzur	Justificar técnicamente la selección del dataset "Photo ID Dataset" disponible en HuggingFace con la generación de credenciales de acceso físicas con fotografías de estudiantes y profesores.	Yamileth, Alejandro

TABLAS

Tabla 1 Alineación del dataset	2
Tabla 2 Comparativas con alternativas	5
Tabla 3 Riesgos y mitigación	6

Contenido

1. Introducción.....	1
2. Dataset seleccionado: Photo Id Dataset	1
2.1. Especificaciones Técnicas	1
2.1.1 Stack de Generación.....	1
2.1.2 Estructura de Datos.....	1
2.2. Justificación técnica de la selección	2
2.2.1 Alineación con Requerimientos del Proyecto.....	2
2.2.2 Ventajas sobre Alternativas	2
2.3. Beneficios técnicos.....	2
2.3.1 Calidad y Consistencia	2
2.3.2 Integración Simplificada.....	2
2.3.3 Escalabilidad	3
2.3.4 Compatibilidad	3
2.4. Aspectos legales y de licencia	3
2.4.1 Licencia Creative Commons Attribution 4.0 International (CC BY 4.0).....	3
2.4.2 Requisitos de Atribución	3
2.4.3 Costos	4
2.5. Consideraciones éticas y de privacidad	4
2.5.1 Ventajas de Datos Sintéticos.....	4
2.5.2 Limitaciones Éticas.....	4
2.6. Aspectos legales adicionales	4
2.6.1 Propiedad Intelectual	4
2.6.2 Responsabilidad Legal	5
2.6.3 Cumplimiento Normativo.....	5
2.7. Comparativa con alternativas	5
2.8. Riesgos y mitigación.....	6
2.8.1 Plan de Contingencia.....	6
3. Conclusión.....	6
4. Referencias.....	7

1. Introducción

El presente documento tiene como objetivo justificar técnicamente la selección del dataset "**Photo ID Dataset**" disponible en HuggingFace para el desarrollo del sistema que requiere la generación de credenciales de acceso físicas con fotografías de estudiantes y profesores.

La necesidad de contar con imágenes realistas para demostraciones educativas, sin comprometer la privacidad de personas reales, hace que los datasets sintéticos representen la solución óptima desde perspectivas técnicas, legales y éticas.

2. Dataset seleccionado: Photo Id Dataset

2.1. Especificaciones Técnicas

Fuente: HuggingFace - lambdaWalker/ds.photo_id

URL: https://huggingface.co/datasets/lambdaWalker/ds.photo_id

Características Principales:

- **Volumen:** 10,000 imágenes sintéticas
- **Formato:** PNG de 512x512 píxeles
- **Calidad:** Alta resolución tipo fotografía profesional
- **Diversidad:** Variación en género, ascendencia, edad y estilos
- **Metadatos:** JSON estructurado con identidades ficticias completas

2.1.1 Stack de Generación

- **Generación de Imágenes:** Flux 1 (características humanas realistas)
- **Procesamiento:** Gemma 3 4B (descripciones y metadatos)
- **Naturaleza:** 100% sintético - todas las identidades son ficticias

2.1.2 Estructura de Datos

Cada registro incluye:

- **Imagen:** Headshot estilo credencial oficial
- **Prompt:** Texto original de generación
- **Descripción:** Características visuales detalladas



- **Card JSON:** Perfil de identidad ficticia completa (nombre, dirección, características físicas, documento de identidad)

2.2. Justificación técnica de la selección

2.2.1 Alineación con Requerimientos del Proyecto

Tabla 1 Alineación del dataset

Requerimiento	Solución del Dataset
Fotografías tipo credencial	Formato ID headshot profesional
Uso educativo/demostrativo	Licencia CC BY 4.0 permite uso comercial y educativo
Sin riesgos de privacidad	100% sintético - personas ficticias
Diversidad representativa	Variación en género, etnia, edad
Calidad profesional	Generado con Flux 1 - alta calidad
Metadatos completos	JSON estructurado con información ficticia
Requerimiento	Solución del Dataset

2.2.2 Ventajas sobre Alternativas

vs. Fotografías Reales:

- Sin necesidad de consentimientos informados
- Sin restricciones de protección de datos personales (GDPR, CCPA)
- Sin riesgos legales por uso de imagen
- Disponibilidad inmediata sin procesos de reclutamiento

vs. Otros Datasets Sintéticos:

- Especializado en formato ID/credencial (no selfies ni fotos casuales)
- Metadatos estructurados listos para usar
- Licencia permisiva CC BY 4.0
- Documentación clara y accesible

2.3. Beneficios técnicos

2.3.1 Calidad y Consistencia

- Todas las imágenes en 512x512 píxeles facilitan el procesamiento
- Sin pérdida de calidad, soporta transparencia si es necesario
- Todas las imágenes siguen el formato de fotografía oficial

2.3.2 Integración Simplificada

- Estructura lista para importar en bases de datos



- Incluye datos demográficos, físicos y de documento
- Útiles para testing de sistemas de búsqueda

2.3.3 Escalabilidad

- 10,000 imágenes permiten pruebas exhaustivas
- Suficiente variación para simular población estudiantil o docentes real
- Al ser sintético, se puede generar más datos si es necesario

2.3.4 Compatibilidad

- PNG compatible con cualquier sistema
- Sin restricciones técnicas de uso
- Disponible vía HuggingFace Datasets library

2.4. Aspectos legales y de licencia

2.4.1 Licencia Creative Commons Attribution 4.0 International (CC BY 4.0)

El dataset está licenciado bajo CC BY 4.0, una de las licencias más permisivas disponibles [opencied.org](https://creativecommons.org/licenses/by/4.0/)

Derechos Otorgados:

- **Compartir:** Copiar y redistribuir el material en cualquier medio o formato
- **Adaptar:** Remezclar, transformar y construir a partir del material
- **Uso comercial:** Permitido incluso para fines comerciales
- **Sin restricciones adicionales:** No se pueden aplicar medidas tecnológicas o legales que restrinjan lo permitido

Requisitos Únicos:

Atribución: Debe darse crédito apropiado al creador

2.4.2 Requisitos de Atribución

Según la licencia CC BY 4.0, para usar este dataset debe:

1. Crédito al autor: Lambdawalker@isdavid.com
2. Enlace a la fuente: https://huggingface.co/datasets/lambdaWalker/ds.photo_id
3. Enlace a la licencia: <https://creativecommons.org/licenses/by/4.0/>
4. Indicar cambios: Si se realizaron modificaciones al dataset



"Photo ID Dataset" by lambdaWalker, licensed under CC BY 4.0.
Source: https://huggingface.co/datasets/lambdaWalker/ds.photo_id

2.4.3 Costos

- **Costo del dataset:** GRATUITO
- **Royalties:** NO APLICA
- **Suscripciones:** NO REQUERIDAS
- **Uso comercial:** PERMITIDO sin pago adicional

2.5. Consideraciones éticas y de privacidad

2.5.1 Ventajas de Datos Sintéticos

Protección de Privacidad:

- Las imágenes son 100% generadas por IA - no corresponden a personas reales
- Elimina riesgos de violación de privacidad
- No requiere consentimiento informado de sujetos
- Cumplimiento automático con regulaciones de protección de datos (GDPR, CCPA, LOPD).

Consideraciones Éticas:

- **Transparencia:** Debe documentarse que las imágenes son sintéticas
- **No engaño:** En demostraciones, aclarar que son personas ficticias
- **Uso responsable:** No usar para crear identidades falsas con fines ilícitos

2.5.2 Limitaciones Éticas

Aspectos a Considerar:

- Aunque son sintéticas, las imágenes pueden parecerse incidentalmente a personas reales
- Los metadatos incluyen información demográfica que debe usarse responsablemente
- Evitar estereotipos en la asignación de roles (estudiante/profesor)

2.6. Aspectos legales adicionales

2.6.1 Propiedad Intelectual

Derechos de Autor:

- El dataset es obra derivada de generación por IA
- La licencia CC BY 4.0 es irrevocable mientras se cumplan los términos



- No hay restricciones de jurisdicción - aplica internacionalmente

Patentes:

- La licencia incluye concesión expresa de derechos de patente
- Sin riesgo de litigio por uso del dataset

2.6.2 Responsabilidad Legal

Limitaciones:

- El dataset se proporciona "TAL CUAL" sin garantías
- El creador no es responsable del uso que se le dé
- La responsabilidad del uso recae en el usuario final

2.6.3 Cumplimiento Normativo

Regulaciones Aplicables:

- **GDPR (Europa):** Al ser datos sintéticos, no aplica protección de datos personales *keymakr.com*
- **CCPA (California):** Exento por no ser información personal real *collegian.com*
- **LOPD/GDD (México/Latinoamérica):** No requiere consentimiento al no ser datos personales

Ventaja Legal:

Los datasets sintéticos evitan las complejidades legales de usar datos biométricos reales, que requieren aprobaciones éticas y comités de revisión.

2.7. Comparativa con alternativas

Tabla 2 Comparativas con alternativas

Dataset	Imágenes	Licencia	Costo	Formato ID	Sintético
Photo ID (seleccionado)	10,000	CC BY 4.0	Gratis	Sí	Sí
Selfie & ID Dataset	150,000	CC BY 4.0	Gratis	Sí	No (reales)
SFHQ Dataset	~14,000	MIT	Gratis	No	Sí
Synthetic Cards	Variable	CC BY 4.0	Gratis	Sí	Sí

- Único dataset enfocado exclusivamente en fotos tipo ID
- 10,000 imágenes es suficiente para demos sin ser excesivo
- Incluye información estructurada lista para usar
- Generado con modelos state-of-the-art (Flux 1, Gemma 3)
- 100% sintético con licencia clara



2.8. Riesgos y mitigación

Tabla 3 Riesgos y mitigación

Riesgo	Probabilidad	Impacto	Mitigación
Similitud incidental con persona real	Baja	Medio	Disclaimer en demostraciones
Cambios en licencia futura	Baja	Alto	Descargar y almacenar localmente
Sesgos en generación IA	Media	Bajo	Diversidad en selección de imágenes
Calidad insuficiente para impresión	Baja	Medio	Pruebas de impresión previas

2.8.1 Plan de Contingencia

Si el dataset no está disponible:

1. Alternativa 1: Generar imágenes sintéticas propias con Stable Diffusion/Flux
2. Alternativa 2: Usar dataset SFHQ y adaptar a formato ID
3. Alternativa 3: Contratar servicio de generación de rostros sintéticos

3. Conclusión

El Photo ID Dataset disponible en HuggingFace representa la solución óptima para el proyecto por las siguientes razones:

- **Técnico:** Imágenes de alta calidad en formato ID profesional
- **Legal:** Licencia CC BY 4.0 permite uso educativo y comercial sin restricciones
- **Ético:** Datos 100% sintéticos protegen privacidad completamente
- **Económico:** Gratuito sin costos ocultos ni royalties
- **Práctico:** Metadatos estructurados facilitan integración

Reducción de riesgos legales sobre GDPR, CCPA y protección de datos al utilizar un dataset de imágenes generado 100% con generadores de imágenes. Las imágenes se generaron con generadores de imágenes que entregan una alta calidad, estos modelos se pueden ejecutar de manera local para tener mayor privacidad, o se puede rentar el uso de tarjetas gráficas en línea, para generar el dataset.

Al utilizar el dataset **Photo ID Dataset disponible en HuggingFace** se logró reducir del 60-80% de tiempo en la recolección de fotos reales.



4. Referencias

1. HuggingFace - Photo ID Dataset. https://huggingface.co/datasets/lambdaWalker/ds.photo_id
2. Creative Commons - CC BY 4.0 License. <https://creativecommons.org/licenses/by/4.0/>
3. OpenSciEd - CC BY 4.0 Requirements. <https://openscienced.org/knowledge/what-does-it-mean-that-these-units-are-licensed-as-cc-by-4-0/>
4. OECD - Creative Commons Toolkit. https://www.oecd.org/en/publications/access-to-public-research-data-toolkit_a12e8998-en
5. GDPR and Synthetic Data Considerations. https://www.edps.europa.eu/system/files/2021-06/03_florian_schroff_en.pdf
6. Legal Considerations of Synthetic Data. <https://keymakr.com/blog/ethical-and-legal-considerations-of-synthetic-data-usage/>
7. HuggingFace Datasets License. <https://github.com/huggingface/datasets/blob/main/LICENSE>

